

Predicción del continuo de cuásares mediante redes neuronales

Modelo basado en redshift y flujo en banda R

Miguel Miranda Viramontes

9 de junio de 2026

Resumen

En este trabajo se estudia la posibilidad de predecir el continuo de cuásares mediante redes neuronales utilizando únicamente parámetros globales, en particular, se emplean como variables de entrada el redshift z y el flujo en la banda R , denotado por FR , mientras que la salida del modelo corresponde al continuo del cuásar evaluado sobre una malla fija de 699 puntos. En una primera etapa se entrenó una red neuronal densa para predecir directamente el continuo completo en su escala natural. Los resultados mostraron que el modelo logra reproducir de manera cualitativa la forma general de los continuos, pero presenta errores importantes en la amplitud global. Para estudiar este comportamiento se introdujo un factor multiplicativo óptimo, A_{opt} , obtenido mediante mínimos cuadrados, el cual permite reescalar la predicción original y cuantificar si la discrepancia principal proviene de la forma o de la escala vertical del continuo. Posteriormente se entrenó una segunda red neuronal con el objetivo de predecir dicho factor óptimo a partir de las mismas variables de entrada, z y FR . Aunque la corrección ideal mediante A_{opt} mejora notablemente algunas predicciones, la red encargada de estimar el factor de corrección tiende a producir valores cercanos a un valor central. Esto sugiere que las variables utilizadas no contienen suficiente información para inferir de manera precisa la amplitud individual de cada continuo. Los resultados indican que el modelo basado únicamente en parámetros globales puede capturar una tendencia promedio de los continuos, pero no reconstruir de manera detallada las variaciones individuales de cada cuásar. Por tanto, para mejorar la predicción sería necesario incorporar información adicional.

1. Introducción

Los cuásares son objetos astrofísicos extremadamente luminosos que pueden ser observados a grandes distancias cosmológicas. Sus espectros contienen información relevante sobre el medio intergaláctico, en particular a través del bosque de Lyman- α . Para estudiar la absorción en esta región, es necesario conocer el continuo intrínseco del cuásar, es decir, el espectro que se observaría en ausencia de absorción. Sin embargo, este continuo no se conoce directamente en la región del bosque, debido a que el flujo observado está modificado por la absorción del medio intergaláctico.

El objetivo de este proyecto es construir un modelo de red neuronal que aproxime el continuo de un cuásar a partir de información disponible sobre estos objetos, en una primera aproximación, se consideran como entradas el redshift z y el flujo en la banda R . La salida de la red es el continuo evaluado sobre una malla fija de puntos.

Este planteamiento es más simple que el utilizado en el modelo LyCAN de la referencia [1]. En dicho trabajo, los autores utilizan una red neuronal convolucional para predecir el continuo no absorbido en el intervalo 1040–1600 Å usando información espectral del lado rojo de la línea Lyman- α , es decir, del intervalo 1216–1600 Å. En contraste, el presente proyecto utiliza únicamente parámetros globales del catálogo, buscando construir con esto la forma de predecir el continuo a partir datos conocidos del objeto astronómico.

2. Descripción de los datos

Los datos utilizados consisten en un catálogo de cuásares y un arreglo que contiene los continuos asociados a cada objeto. La información relevante para este proyecto de dicho catálogo consiste en la identificación del objeto astronómico, el redshift y su flujo en banda R .

Por otro lado, el continuo de cada cuásar está representado por un vector de 699 puntos. Por tanto, si el catálogo contiene N objetos, el arreglo de continuos tiene dimensión

$$Y \in \mathbb{R}^{N \times 699}.$$

Cada fila de Y representa el continuo de un cuásar:

$$Y_i = [C_i(\lambda_1), C_i(\lambda_2), \dots, C_i(\lambda_{699})]. \quad (1)$$

La entrada del modelo se define como

$$X_i = (z_i, FR_i), \quad (2)$$

de modo que el objetivo inicial es que a partir de una entrada de la forma X , podamos encontrar un continuo asociado a esta.

3. Preprocesamiento

Antes de entrenar la red neuronal, se eliminaron las filas con valores no finitos, es decir, con valores NaN o infinitos tanto en las entradas como en las salidas. Esto fue necesario pues la presencia de valores no permitía el entrenamiento de la red.

Posteriormente, los datos se dividieron en tres subconjuntos:

- entrenamiento,
- validación,
- prueba.

El conjunto de entrenamiento se utiliza para enseñar a la red a predecir los patrones intrínsecos de los continuos debidos a los cambios en los parámetros usados, el conjunto de validación permite monitorear el desempeño durante el entrenamiento y finalmente, el conjunto de prueba se reserva para evaluar el modelo final.

4. Modelo directo

En una primera instancia se realizó la red neuronal densa de modo que intentara predecir directamente el continuo completo a partir de z y FR . La arquitectura utilizada fue de la forma

$$(2) \longrightarrow (64, \text{ReLU}) \longrightarrow (128, \text{ReLU}) \longrightarrow (256, \text{ReLU}) \longrightarrow (N_{\text{puntos}}, \text{lineal})$$

La capa de entrada recibe vectores de 2 características, después vienen 3 capas ocultas densas, estas capas aprenden combinaciones no lineales de las dos entradas, La red aumenta progresivamente su número de neuronas intentando aprender una relación no lineal entre los parámetros globales del espectro y el continuo completo y finalmente, la capa de salida produce un vector de 699 puntos.

Este modelo logró reproducir de manera cualitativa la forma general del continuo, pero se observó que las predicciones aparecían desplazadas verticalmente respecto al continuo real. En otras palabras, el modelo capturaba parcialmente la forma, pero no la amplitud global como puede verse en la Figura 1.




Figura 1: Predicciones realizadas mediante el primer modelo

4.1. Corrección multiplicativa mediante un factor óptimo

Al analizar las predicciones se observó que la red neuronal reproducía de manera aproximada la forma general del continuo, pero con una amplitud incorrecta. Es decir, la predicción podía estar sistemáticamente por debajo o por encima del continuo real aunque la estructura de la curva fuera similar. Para estudiar este efecto, se introdujo un factor multiplicativo óptimo que permite re escalar la predicción del modelo.




Figura 2: Predicciones realizadas mediante el primer modelo y con corrección del factor multiplicativo

Sea C_j^{real} el valor real del continuo en el punto j de la malla, y sea C_j^{pred} la predicción correspondiente producida por la red neuronal. Se busca un factor A tal que la curva re escalada

$$C_j^{\text{corr}} = AC_j^{\text{pred}} \quad (3)$$

se aproxime lo mejor posible al continuo real. Para ello se minimiza el error cuadrático

$$E(A) = \sum_{j=1}^{N_\lambda} \left(C_j^{\text{real}} - AC_j^{\text{pred}} \right)^2, \quad (4)$$

donde $N_\lambda = 699$ es el número de puntos de la malla del continuo. Derivando respecto a A e imponiendo la condición de mínimo,

$$\frac{dE}{dA} = 0, \quad (5)$$

se obtiene

$$-2 \sum_{j=1}^{N_\lambda} C_j^{\text{pred}} \left(C_j^{\text{real}} - A C_j^{\text{pred}} \right) = 0. \quad (6)$$

Por tanto, el factor multiplicativo óptimo está dado por

$$A_{\text{opt}} = \frac{\sum_{j=1}^{N_\lambda} C_j^{\text{real}} C_j^{\text{pred}}}{\sum_{j=1}^{N_\lambda} \left(C_j^{\text{pred}} \right)^2}. \quad (7)$$

Este factor representa la mejor corrección global de amplitud, en el sentido de mínimos cuadrados, para una predicción dada. Si $A_{\text{opt}} > 1$, entonces la red predijo una amplitud demasiado baja; si $A_{\text{opt}} < 1$, la red predijo una amplitud demasiado alta. En cambio, si $A_{\text{opt}} \simeq 1$, la escala de la predicción original ya era cercana a la correcta.

Como evidencia de que dicho factor mejora la predicción véase la Figura 2, la cual muestra la mejora en la reproducción de los continuos al agregar este factor.

Es importante notar que A_{opt} no puede utilizarse directamente como una predicción para objetos nuevos, ya que su cálculo requiere conocer el continuo real. Por esta razón, en este trabajo se emplea inicialmente como una herramienta de diagnóstico: permite determinar si los errores del modelo provienen principalmente de una mala estimación de la amplitud o de una mala reconstrucción de la forma del continuo.

Posteriormente, se entrenó una segunda red neuronal con la intención de aprender este factor a partir de las mismas variables de entrada del modelo original. Es decir, mientras la primera red aprende la relación

$$(z, FR) \longrightarrow C^{\text{pred}}(\lambda), \quad (8)$$

la segunda red intenta aprender

$$(z, FR) \longrightarrow A_{\text{opt}}. \quad (9)$$

De esta manera, la predicción final corregida se construye como

$$C^{\text{final}}(\lambda) = A_{\text{pred}} C^{\text{pred}}(\lambda), \quad (10)$$

donde A_{pred} es el factor multiplicativo estimado por la segunda red neuronal. En la práctica, se entrena esta segunda red usando $\log_{10}(A_{\text{opt}})$ como variable objetivo, ya que el factor puede variar en varios órdenes de magnitud y una escala logarítmica resulta más estable para el entrenamiento.

Esta estrategia permite conservar el modelo directo que predice el continuo completo en su escala natural, pero añade una corrección posterior de amplitud. Además, proporciona una comparación útil entre tres casos: la predicción original, la predicción corregida con el factor aprendido A_{pred} y la predicción ideal corregida con el factor óptimo A_{opt} . Si la corrección ideal mejora las predicciones, pero la corrección aprendida no lo hace, esto indica que el factor de escala sería útil, pero que las variables de entrada disponibles no contienen suficiente información para inferirlo correctamente.

4.2. Entrenamiento de la red de corrección

Para el entrenamiento de la segunda red neuronal, se realizó una red neuronal densa de modo que intentara predecir el valor de reescalamiento A_{opt} , siendo que la arquitectura utilizada fue de la forma

$$(2) \longrightarrow (32, \text{ReLU}) \longrightarrow (64, \text{ReLU}) \longrightarrow (64, \text{ReLU}) \longrightarrow (32, \text{ReLU}) \longrightarrow (1, \text{lineal})$$

La capa de entrada recibe vectores de 2 características, después vienen 4 capas ocultas densas, estas capas aprenden combinaciones no lineales de las dos entradas, La red aumenta su número de neuronas para posteriormente reducirlo, pues el producto final solo es un número, con esto intenta aprender una relación no lineal entre los parámetros globales del espectro y el factor de corrección, finalmente, la capa de salida produce el factor de corrección.

Con esta corrección el modelo logró mejorar de manera significativa la forma general del continuo, pero se observó que los factores de corrección predichos no se asemejan a los reales, lo que puede indicar que solo con z y FR no es suficiente para que la red neuronal discierna la información del valor de corrección óptimo, pues el predicho tiende a ser un valor central, lo cual es un indicativo de que la red neuronal no está aprendiendo a diferenciarlos a partir de estos parámetros.

Lo anterior se ve de forma más clara en la Figura 3.




Figura 3: Predicciones realizadas mediante la corrección del factor multiplicativo predicho.

5. Conclusiones

En este proyecto se exploró el uso de redes neuronales densas para predecir el continuo de cuásares a partir de parámetros globales. En particular, se utilizaron como variables de entrada el redshift z y el flujo en banda R , mientras que la salida del modelo consistió en un vector de 699 puntos que representa el continuo asociado a cada objeto.

El primer modelo implementado fue una red neuronal densa entrenada para predecir directamente el continuo completo. Este modelo permitió reproducir de manera aproximada la forma general de los continuos, lo cual indica que la red sí logra aprender ciertas tendencias globales presentes en los datos. Sin embargo, al comparar las predicciones con los continuos reales, se observó que una parte importante del error provenía de una mala estimación de la amplitud global. En varios casos, la curva predicha tenía una forma similar a la real, pero aparecía desplazada verticalmente o con una escala incorrecta.

Para analizar este comportamiento se introdujo un factor multiplicativo óptimo A_{opt} , obtenido mediante la minimización del error cuadrático entre el continuo real y la predicción reescalada. Este factor permitió comprobar en algunos objetos que una simple corrección global de amplitud mejora considerablemente la reconstrucción del continuo. Por tanto, el cálculo de A_{opt} funcionó como una herramienta de diagnóstico útil para distinguir entre errores asociados a la forma de la curva y errores asociados a su escala vertical.

Posteriormente, se entrenó una segunda red neuronal con el propósito de predecir el factor de corrección A_{opt} a partir de las mismas variables de entrada, z y FR . Esta estrategia buscaba construir una predicción corregida de la forma

$$C^{\text{final}}(\lambda) = A_{\text{pred}} C^{\text{pred}}(\lambda), \quad (11)$$

donde A_{pred} es el factor estimado por la segunda red. No obstante, los resultados indican que la red de corrección no logra reproducir adecuadamente los valores óptimos individuales, sino que tiende a predecir valores cercanos a una región central. Esto sugiere que, aunque el factor multiplicativo ideal puede mejorar las predicciones, las variables z y FR no contienen suficiente información para inferirlo de manera confiable.

A partir de estos resultados se concluye que debido a la limitación en la información disponible en las entradas. La red no cuenta con suficientes variables para distinguir de manera detallada las diferencias individuales entre los continuos de distintos cuásares. En consecuencia, el modelo tiende a aprender una representación promedio o una tendencia global de los datos, en lugar de reconstruir con precisión el continuo particular de cada objeto.

En conclusión, el modelo desarrollado representa una primera aproximación útil para estudiar la relación entre parámetros globales de cuásares y sus continuos asociados. Sin embargo, los resultados muestran que para obtener predicciones más precisas será necesario incorporar información adicional. Estas extensiones permitirían construir un modelo con mayor capacidad para capturar tanto la amplitud como la forma individual del continuo de cada cuásar.

Declaración de uso de inteligencia artificial

Durante la elaboración de este trabajo se utilizó una herramienta de inteligencia artificial generativa como apoyo para la corrección de errores en código debido al tiempo para la implementación del proyecto. Además, se utilizó para inferir la manera del reescalamiento de los continuos generados por el modelo duro cabe destacar que su función fue el de una herramienta de apoyo.

Referencias

- [1] W. Turner et al., *New measurements of the Lyman- α forest continuum and effective optical depth with LyCAN and DESI Y1 data*, arXiv:2405.06743v2, 2024.
- [2] M. Abadi et al., *TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems*, Software available from tensorflow.org, 2015.
- [3] F. Pedregosa et al., *Scikit-learn: Machine Learning in Python*, Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.